

Rapport du Projet de Text Mining

Pipeline complet d'analyse textuelle :
De l'EDA à la recommandation

RÉALISÉ PAR
Abderrahim AZEROUAL

ENCADRÉ PAR
Pr. Imad HAFIDI

Table des matières

1	Introduction générale	2
1.1	Contexte du projet	2
1.2	Objectifs du TP	2
2	Analyse exploratoire des données (EDA)	2
2.1	Chargement et inspection des données	2
2.2	Distribution des sentiments	3
2.3	Distribution des langues (dataset multilingue)	3
2.4	Distribution de la longueur des textes	3
2.5	Corrélation rating - sentiment	4
3	Prétraitement du texte	4
3.1	Pipeline Classique	4
3.2	Pipeline Léger (Light)	5
3.3	Exemple de résultats	5
4	Vectorisation des textes	5
4.1	Principe du TF-IDF	5
4.2	Méthodes comparées	6
5	Classification des sentiments	6
5.1	Modèles utilisés	6
5.2	Résultats obtenus	6
6	Modélisation des topics	7
6.1	LDA (Latent Dirichlet Allocation)	7
	Paramètres d'entraînement	7
	Évaluation	7
6.2	Comparaison LDA vs BERTopic	7
7	Système de recommandation	8
7.1	Principe	8
7.2	Score hybride	8
7.3	Avantages du système	8
8	Comparaison mono-langue vs multilingue	9
9	Conclusion et perspectives	9
9.1	Bilan	9
9.2	Limites et améliorations possibles	9
9.3	Conclusion générale	9

Introduction générale

Le traitement automatique du langage naturel (NLP) constitue aujourd'hui un domaine fondamental de l'intelligence artificielle, permettant d'extraire des connaissances pertinentes à partir de données textuelles non structurées. Ce TP s'inscrit dans ce contexte en proposant un pipeline complet d'analyse textuelle, allant de l'exploration des données brutes jusqu'à la recommandation de produits.

1.1 Contexte du projet

Dans un monde où les utilisateurs génèrent quotidiennement d'immenses volumes d'avis, de commentaires et de critiques en ligne, la capacité à analyser automatiquement ces textes est devenue cruciale pour les entreprises et les chercheurs. Ce TP met en œuvre un pipeline de Text Mining sur deux jeux de données d'avis produits :

- Un **dataset mono-lingue** (anglais) contenant 500 avis avec 5 colonnes : `review_id`, `text`, `rating` (1–5), `sentiment` (positive/neutral/negative) et `product_category` (fashion, home, electronics).
- Un **dataset multilingue** contenant 4500 avis en 5 langues (arabe, darija arabe, darija arabizi, anglais, français), avec une colonne supplémentaire `language`, répartis équitablement (900 par langue).

1.2 Objectifs du TP

Les objectifs principaux de ce TP sont les suivants :

1. **Explorer** les données textuelles pour en comprendre la structure et les caractéristiques ;
2. **Prétraiter** les textes via des techniques de nettoyage, tokenisation et lemmatisation ;
3. **Vectoriser** les documents à l'aide de méthodes comme TF-IDF ;
4. **Classifier** les sentiments en utilisant des modèles de machine learning ;
5. **Modéliser les topics** pour découvrir les thèmes latents dans les corpus ;
6. **Recommander** des produits similaires en exploitant les représentations vectorielles.

Analyse exploratoire des données (EDA)

L'analyse exploratoire constitue la première étape du pipeline. Elle permet de comprendre la structure des données, d'identifier les distributions et de détecter d'éventuelles anomalies.

2.1 Chargement et inspection des données

Les deux datasets sont chargés depuis des fichiers CSV. L'inspection révèle les caractéristiques suivantes :

Caractéristique	Mono-langue	Multilingue
Nombre d’avis	500	4 500
Nombre de colonnes	5	6
Rating moyen	2.94	3.03
Langues	Anglais uniquement	5 langues
Catégories de produits	3	Multiples

TABLE 1 – Statistiques descriptives des deux jeux de données.

2.2 Distribution des sentiments

L’analyse de la distribution des sentiments montre :

- **Dataset mono-langue** : distribution relativement équilibrée avec 175 avis négatifs, 171 neutres et 154 positifs.
- **Dataset multilingue** : distribution parfaitement équilibrée avec exactement 1 500 avis par catégorie de sentiment.




FIGURE 1 – Distribution des sentiments pour les deux datasets

2.3 Distribution des langues (dataset multilingue)

Le dataset multilingue est composé de 5 langues, chacune représentant exactement 20% du corpus (900 avis) : arabe, darija arabe, darija arabizi, anglais et français.

2.4 Distribution de la longueur des textes

L’analyse de la longueur des textes (nombre de caractères) permet d’identifier la variabilité des avis.




FIGURE 2 – Comparaison des longueurs de textes entre mono-lingue et multilingue

2.5 Corrélation rating - sentiment




FIGURE 3 – Alignement entre les ratings numériques (1-5) et les sentiments catégorisés

Prétraitement du texte

Le prétraitement est une étape cruciale qui conditionne directement la qualité des résultats en aval.

3.1 Pipeline Classique

Le pipeline classique applique les traitements suivants :

1. **Normalisation** : conversion en minuscules, suppression des URLs
2. **Suppression de la ponctuation**

3. Tokenisation : découpage du texte en tokens

4. Filtrage : suppression des stopwords

5. Lemmatisation : réduction des mots à leur forme canonique

3.2 Pipeline Léger (Light)

Le pipeline léger applique un nettoyage minimal : conversion en minuscules, suppression des URLs, sans suppression des stopwords ni lemmatisation. Il est adapté aux modèles de deep learning.

3.3 Exemple de résultats

Texte original	Pipeline Classique	Pipeline Léger
Great value for money	[great, value, money]	[great, value, for, money]
I love it, will definitely buy again	[love, definitely, buy]	[i, love, it, will, definitely, buy, again]
Works perfectly and arrived quickly	[work, perfectly, arrive, quickly]	[works, perfectly, and, arrived, quickly]

TABLE 2 – Comparaison des deux pipelines de prétraitement.

Vectorisation des textes

La vectorisation transforme les textes nettoyés en vecteurs numériques exploitables.

4.1 Principe du TF-IDF

La pondération TF-IDF combine deux mesures :

- **TF (Term Frequency)** : fréquence d'un terme dans un document
- **IDF (Inverse Document Frequency)** : inverse de la fréquence dans le corpus

La formule globale est :

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \left(\frac{N}{\text{DF}(t)} \right)$$

où N est le nombre total de documents et $\text{DF}(t)$ le nombre de documents contenant le terme t .

4.2 Méthodes comparées

Méthode	Type	Dimension
Bag of Words	Comptages	vocabulaire
TF-IDF	Pondération	vocabulaire
FastText	Embeddings	300D
Sentence-BERT	Embeddings sémantiques	384D

TABLE 3 – Comparaison des méthodes de vectorisation.

Classification des sentiments

Objectif

Prédire automatiquement le sentiment (positif, neutre ou négatif) à partir du texte nettoyé.

5.1 Modèles utilisés

Plusieurs algorithmes de classification supervisée ont été évalués :

- **Logistic Regression** : modèle linéaire rapide et interprétable
- **SVM (Support Vector Machine)** : très performant pour les données de haute dimension
- **Random Forest** : ensemble de décisions basé sur des arbres

5.2 Résultats obtenus

Modèle	Vectorisation	Accuracy
Régression Logistique	TF-IDF	100%
SVM	TF-IDF	100%
Régression Logistique	SBERT	100%

TABLE 4 – Performances des modèles de classification.

Résultat Exceptionnel

Tous les modèles atteignent une accuracy de 100%, ce qui indique :

- Une séparabilité linéaire parfaite des trois classes
- Un vocabulaire très discriminant
- Une excellente qualité des données




FIGURE 4 – Matrice de confusion pour le meilleur modèle de classification

Modélisation des topics

La modélisation des topics vise à découvrir automatiquement les thèmes latents présents dans le corpus.

6.1 LDA (Latent Dirichlet Allocation)

Le modèle LDA est un modèle probabiliste génératif qui considère chaque document comme un mélange de topics.

Paramètres d'entraînement

- num_topics=10
- passes=50
- iterations=100

Évaluation

L'évaluation repose sur deux métriques :

- **Perplexité** : plus faible = meilleur ajustement
- **Cohérence** (c_v) : plus élevée = meilleure interprétabilité

6.2 Comparaison LDA vs BERTopic

Méthode	Avantages	Inconvénients
LDA	Interprétable, peu paramètres	Topics parfois génériques
BERTopic	Topics focalisés, sémantiques	Moins interprétable

TABLE 5 – Comparaison des approches de topic modeling.




FIGURE 5 – Distribution des topics dans le corpus (LDA vs BERTopic)

Système de recommandation

7.1 Principe

Le système est basé sur le contenu (*content-based filtering*) utilisant la **similarité cosinus** entre les vecteurs TF-IDF des avis.

7.2 Score hybride

La recommandation combine plusieurs critères :

$$S = \alpha \cdot \text{Sim} + \beta \cdot \text{Sent} + \gamma \cdot \text{Topic}$$

avec $\alpha + \beta + \gamma = 1$.

7.3 Avantages du système

- **Diversité** des recommandations
- **Contextualité** basée sur le contenu
- **Explicabilité** des suggestions

Produit Recommandé	Catégorie	Score de Similarité
Produit A	Electronics	0.85
Produit B	Electronics	0.82
Produit C	Electronics	0.78

TABLE 6 – Exemple de produits recommandés avec leurs scores

Comparaison mono-lingue vs multilingue

Aspect	Mono-lingue	Multilingue
Prétraitement	Standard	Adaptation par langue
Vocabulaire	Restreint	Très large
Classification	Performance parfaite	Performance variable
Topics	Thèmes anglais	Thèmes mixtes multilingues

TABLE 7 – Comparaison systématique entre mono-lingue et multilingue.

Conclusion et perspectives

9.1 Bilan

Ce TP a permis de mettre en œuvre un pipeline complet de Text Mining avec :

- Une **architecture modulaire** et extensible
- Des **méthodes comparées** rigoureusement (TF-IDF vs embeddings, LDA vs BERTopic)
- Une **validation robuste** (cross-validation 5-folds)
- Des **résultats exceptionnels** (100% en classification)
- Un **système appliqué** de recommandation

9.2 Limites et améliorations possibles

Limitations actuelles :

- Dataset mono-lingue de petite taille (500 avis)
- Classification parfaite suggérant une tâche simplifiée

Améliorations futures :

- Fine-tuning de transformers modernes (BERT, Llama)
- Aspect-based sentiment analysis
- Recommandations collaboratives
- Analyse temporelle des sentiments
- Interprétabilité avancée (LIME, SHAP)

9.3 Conclusion générale

Le text mining, quand systématiquement appliqué, transforme des textes bruts en **insights actionnables** et applications pratiques (classification, recommandation, analytics). Ce pipeline est directement transférable à des contextes réels comme l'analyse de feedback clients ou le support client automatisé.